

Rapport de Stage

Andrea Marchive

June 2026

1 Introduction

Dire que le monde est envahi par les “fake news”, les fausses informations, n’est une surprise pour personne. Entre les réseaux sociaux qui débordent d’influenceurs qui propagent de fausses idées à des buts pécuniers, et les hommes politiques qui ignorent de plus en plus souvent la vérité pour raconter des faits qui arrangent leurs intérêts, un citoyen lambda est facilement submergé, et ne sait plus distinguer le faux du vrai. Heureusement, il reste encore des gardiens de la vérité (ou plutôt, de la factualité) ; les journalistes, et plus précisément dans notre cas, les fact-checkers.

Cependant, leurs efforts ne suffisent pas à faire face à la quantité de fausses informations qui circulent sur internet. Si cela a toujours été le cas, l’hégémonie des réseaux sociaux et des algorithmes comme source d’information vernaculaire rend cette réalité encore plus terrifiante. Les citoyens s’informent plus que jamais à l’aide de ces réseaux sociaux, et ne font souvent pas forcément attention à vérifier la véracité des informations qu’on leur montre. Cela s’est encore une fois empiré avec l’apparition des Intelligences Artificielles (IA) générative et des Large Language Models (LLM). Si ceux-ci peuvent être des outils intéressants, une partie de la population a tendance à leur faire confiance trop facilement et à ignorer les risques d’hallucination.

Les fact-checkers ne peuvent donc pas faire face à la quantité de fausses informations sur internet. Il semble alors logique que, dans le but de les aider, des informaticiens essayent de créer des systèmes permettant de faire du fact-checking grâce à des algorithmes. Ces technologies sont désignées par le sigle “AFC”, pour “Automated Fact-Checking”. C’est un sujet qui est étudié depuis longtemps et qui est assez complexe. Cette complexité découle principalement de trois choses.

Déjà, il est assez difficile pour un algorithme de savoir si quelque chose est objectivement “vrai”. Si cela est possible pour les informations déjà connues, comme des faits politiques ou économiques, ou des cas de désinformations qui ont déjà été traités par des journalistes, il est presque impossible pour un algorithme traditionnel d’explorer des territoires qui lui sont inconnus. Ensuite, une grande partie de la désinformation qu’on peut trouver sur internet est multimodale. Une fake-news n’est que rarement seulement du texte. On trouve souvent une vidéo ou une image qui l’accompagne. Adresser cette multimodalité est crucial, mais rarement simple. Enfin, un système d’AFC se doit d’être explicable. L’AFC est destiné à être utilisé par des personnes qui ne sont pas forcément éduquées sur le fonctionnement précis d’une IA, et il n’est donc pas nécessaire qu’elle soit interprétable. Cependant, pour être pris au sérieux, le fact-checking nécessite un raisonnement logique, humain, et reproductible par une personne lambda. On voit alors souvent les systèmes d’AFC citer leurs sources, ou indiquer quels éléments du média donné en entrée ont été utilisés pour mener à la conclusion présentée.

En accord avec l’importance du sujet, de nombreux AFC ont été créés à travers les 15 dernières années. Certains sont même assez impressionnants et parviennent à faire face aux problèmes présentés avec une justesse remarquable. De même, il existe d’excellents benchmarks, certains étant même régulièrement mis à jour par leurs créateurs. Certains systèmes d’AFC sont même disponibles à l’échelle du grand public. En France, on trouve par exemple *Ask Vera*, un numéro de téléphone sur *WhatsApp* qui répond aux questions posées par les utilisateurs.

L’objectif originel de ce stage était d’essayer de créer un système d’AFC qui aurait été multimodal et explicable à tous les niveaux (dans le sens que le système ferait plus que simplement citer une source secondaire). Cependant, durant la phase de recherche sur le sujet, une certaine réalité s’est révélée, et elle a changé la trajectoire de ce stage.

Dans la première partie de ce rapport de stage, ces recherches seront alors résumées et le raisonnement qui a mené au changement d’objectif sera expliqué. Dans la seconde partie, le projet qui a finalement été réalisé sera présenté, et nous adresserons les pistes futures que celui-ci présente.

2 Recherches autour des systèmes d’AFC

Comme souvent dans un stage se déroulant dans le milieu de la recherche, la première tâche donnée était de se familiariser avec le sujet, tant bien sur le côté technologique, que sur le côté journalistique. Dans cette partie, nous établirons tout d’abord un court état de l’art quant au sujet des systèmes d’AFC. Ensuite, nous explorerons le côté journalistique du sujet ; ce que représente le fact-checking pour un journaliste, et ce que ces professionnels attendent d’un système d’AFC. Enfin, nous adresserons certains articles scientifiques qui ont été particulièrement impactant au cours de ces recherches. Des articles qui avaient pour objectif de réellement lier ces deux mondes, et qui ont fortement influencé le reste du stage.

2.1 Court état de l’art

Le fact-checking est un domaine très complexe, et il semble donc logique que de nombreuses techniques ont été explorées. Cependant, la majorité comportent certaines similarités, et fonctionnent en plusieurs étapes.

La première est la détection et l’extraction de ce qui est affirmé par les données en entrée. Cette affirmation est appelée le “claim”, et son identification est un point crucial du système. Toute la chaîne de raisonnement du système dépend de cette détection. Si le mauvais claim est extrait, alors le système ne sert à rien.

La difficulté de cette extraction est renforcée par la nature complexe et souvent multimodale des données en entrée. Un post sur Tiktok n’est pas que du texte ; c’est une vidéo, de l’audio, et souvent, du texte qui est présent sur l’écran.

Une fois le claim identifié, le système essaie de trouver des éléments connus comme “vrai” qui pourraient soutenir ou réfuter le claim. Ces éléments peuvent être enregistré dans le système d’AFC (en téléchargeant des articles de presse, par exemple), ou ils peuvent être récoltés au besoin depuis internet. Cette seconde option, même si plus complexe et souvent plus couteuse, est largement préférable, étant donné que la factualité d’une information peut changer très rapidement.

Enfin, ces éléments sont comparés au claim identifié, et celui-ci est classifié comme étant “vrai” ou “faux”. Cette classification est souvent plus complexe et les catégories “vrai” et “faux” sont réparties en plusieurs sous-catégories, comme “hors-contexte”, “presque vrai”, “à moitié faux”, etc. Cela suit les nomenclatures utilisées par de nombreux sites de fact-checking (<https://www.snopes.com/fact-check-ratings/>).




Figure 1: Processus standard d’un système d’AFC.

Si cela permet de se rapprocher de ce qui est fait dans le métier d’un journaliste, cela a aussi des inconvénients. Une classification binaire est toujours plus simple à comprendre qu’une classification plus floue comme “à moitié vrai”.

Une autre approche est alors de répartir l’état de véracité d’une information en plusieurs propriétés. Dans l’article de recherche VERITAS [5], la factualité d’un claim est vérifiée en trois grandes étapes. D’abord, l’authenticité du média est vérifiée. Ici, le terme “authenticité” questionne si le média a été générée par une IA ou s’il il a été malicieusement modifié. Si le média est déterminé comme étant authentique, alors sa contextualisation est vérifiée. Cela désigne si le média est présenté dans son contexte original, où il a été créé, ou s’il en a été sorti afin de dire une information qui est fausse. On peut par exemple penser à des gens

qui prendraient des images d’une guerre qui s’était déroulée il y a des années, et qui les utiliseraient pour insinuer qu’un pays est actuellement en train d’être attaqué. Enfin, si le contexte est correct, ou qu’il n’y en a pas, alors la véracité du claim en lui-même est questionnée. On regarde alors si le claim qui est porté par les données fournies est soutenu par des informations dont la véracité est connue par le système d’AFC.

Cette dernière étape est celle que nous associons le plus souvent au travail d’un fact-checker, mais en réalité, les autres sont souvent plus importantes, et surtout, plus difficiles. Retrouver la source originale d’un média est souvent bien plus complexe que de simplement chercher sur internet si une information est vraie ou fausse. Pareillement, identifier si une vidéo ou une image a été générée ou manipulée est bien plus complexe qu’il n’y paraît. C’est pour cela que, dans le cadre de ce stage, la base de données fournie par VERITAS a été utilisée. Nous pensons que son approche est un pas nécessaire vers la réalité journalistique.




Figure 2: Processus de définition de la vérité comme présenté dans VERITAS.

Une fois le pipeline d’un système d’AFC établi, il faut choisir comment faire fonctionner cet AFC. Et, sans surprise, la tendance actuelle dans le fact-checking automatique tourne autour des LLM. Ceci est assez logique, considérant que le fact-checking est un sujet qui implique l’utilisation et l’analyse de langage naturel, et que les LLM sont les meilleurs dans ce domaine. De plus, de nombreux LLM sont désormais capable d’analyser des images et, dans certains cas, des vidéos.

Certains systèmes, comme 3M-Fact présent dans l’article qui introduit le dataset TRUE [4], mettent alors en place plusieurs LLM qui se répartissent les différentes tâches, qui communiquent entre eux, et qui vont sur Internet pour trouver des informations. Cela permet à ces systèmes d’atteindre de bien meilleurs résultats que ceux utilisant des techniques plus traditionnelles.

Cependant, l’utilisation de LLM implique souvent un manque d’explicabilité, et le domaine de l’AFC ne manque pas à la règle. Si ces systèmes sont capables de citer leurs sources, et pourquoi ces sources ont été choisies, on ne retrouve pas un raisonnement plus humain, un raisonnement que l’on pourrait retrouver dans




Figure 3: Schéma de fonctionnement de 3M-Fact.

un article d'un journaliste fact-checker.

Cela amène à des questions qui semblent cruciales, et qui ne sont pourtant que rarement adressées. Quelles sont les méthodes des journalistes fact-checkers ? Quels sont leurs critères ? Quelle est leur vision du fact-checking, leur compréhension de la "vérité" ? Que cherche les fact-checkers d'un système d'AFC ?

2.2 Le point de vue des journalistes

Pour répondre à ces questions, j'ai eu la chance de pouvoir assister aux Assises du Journalisme, qui ont eu lieu à Tours du 7 au 11 avril 2026. J'ai pu m'y rendre le jeudi 9 avril, et j'ai pu assister aux ateliers et aux conférences suivantes :

- ATELIER RECHERCHE ET JOURNALISME : UNE HISTOIRE DU FACT-CHECKING, avec Pascal Froissart, Professeur des Universités au CELSA et Eric Lagneau, journaliste à l'AFP, et animé par Claire Blandin (Université Sorbonne Paris-Nord).

- ATELIER RECHERCHE ET JOURNALISME : DÉSORDRES INFORMATIONNELS : QUAND LA VÉRITÉ ÉCHAPPE AUX JOURNALISTES..., avec Christophe Deleu (Université de Strasbourg) ; Clément Legros, journaliste OSINT pour Les Révélateurs (France TV) ; Arnaud Mercier (Université Paris Panthéon-Assas) et Angèle Stalder (Université Jean Moulin Lyon 3), et animé par Lucie Alexis (Université Grenoble Alpes) et Céline Ségur (Université de Lorraine).

- VRAIES IMAGES, FAUSSES IMAGES : L'I.A. REDEFINIT-ELLE LA VÉRITÉ JOURNALISTIQUE ? Avec Flore di Sciuillo, docteure en sciences de l'information et de la communication et chercheuse associée au laboratoire CARISM (Université Panthéon-Assas) ; Isabelle Toubant, rédactrice en chef adjointe, en charge de la gestion de l'ensemble des images vidéo pour TF1, LCI et le digital (Groupe TF1) et François-Xavier Marit, rédacteur en chef technique photo de l'AFP, et présenté par Arnaud Mercier.

Assister à ces conférences m'a permis de mieux comprendre le travail des journalistes fact-checker. La vision de leur métier n'est pas forcément la même que celle d'un citoyen lambda pourrait avoir, et cette réalisation a changé ma perception des systèmes d'AFC.

Pour un journaliste, le fact-checking est un travail qui est pris très au sérieux, mais qui est aussi réalisé en ayant conscience de la futilité de leurs actes. Les journalistes savent qu'il y a bien trop de fake news, et qu'ils ne pourront jamais créer une réelle différence. L'exercice du fact-checking est d'ailleurs souvent confié à des journalistes qui débutent, car c'est un processus qui est apparemment très formateur.

Et ce processus est bien plus complexe que celui que les systèmes d'AFC essayent souvent d'imiter. Par ailleurs, le travail du journaliste commence bien avant le traitement de l'information ou la rédaction de l'article. Le début de tout processus de fact-checking consiste à faire des décisions éditoriales sur si la fake news devrait être vérifiée. En effet, certaines informations sont trop dures à vérifier, et d'autres ne doivent pas être vérifiées. Dans cette catégorie, qui peut sembler étrange au premier abord, on trouve d'abord le "bullshit". Ce terme désigne une information qui, par nature, ne peut pas être vérifiée, et cela car elle n'est pas basée dans la réalité. On retrouve alors, par exemple, un post de Donald Trump qui se proclame le président le plus intelligent de l'histoire. Ceci n'est pas une information qui peut être vraie ou fausse, car

elle ne peut pas être vérifiée. Ecrire un article dessus reviendrait par ailleurs à lui donner de la crédibilité, paradoxalement. Car un article de fact-checker peut malheureusement souvent porter plus d'attention sur la fake news, que sur la vérité qui est présentée dans l'article. Les journalistes doivent alors également faire attention à ne pas fact-checker des publications qui ne sont pas assez connues, afin d'éviter un effet Streisand.

Une fois le processus éditorial terminé, le journaliste peut donc s'attaquer à la vérification de l'information portée par le post choisi. Mais ici encore, les journalistes sont bien plus rigoureux que les systèmes d'AFC. Quand le contenu est multimodal, ils commencent souvent par une vérification de l'authenticité du média. S'ils peuvent utiliser certains outils informatiques pour s'aider, ils ne s'en contentent jamais. Et peu importe le résultat de l'analyse de cette authenticité, un fact-checker prendra ensuite le temps de vérifier si le contexte du média donné est correct et respecté. Ici, ils utilisent principalement la Recherche par Image Inversée (ou RIS, pour Reverse Image Search), qui permet de savoir si cette image a déjà été utilisée autre part sur internet. L'écrasante majorité des fake news adressées par les journalistes rentrent par ailleurs dans cette catégorie ; un contexte manipulé.

Si le contexte est correct, ou alors qu'aucun n'est nécessaire, alors les journalistes vérifient la véracité de l'information. Les journalistes sont alors souvent requis de posséder au moins deux sources primaires (i.e. un livre, une interview, des chiffres officiels). L'utilisation d'une source secondaire, ce qui est actuellement le standard d'explicabilité des systèmes d'AFC, est une pratique qui est presque moquée dans le monde journalistique.

Une fois cela fini, les journalistes savent souvent si l'information est vraie ou fausse. Cependant, ils ne s'arrêtent pas là. Très souvent, les journalistes cherchent à rentrer en contact avec les personnes concernées par la fake news. Cela peut par exemple impliquer de communiquer avec le porte-parole d'une personnalité politique concernée. C'est seulement quand toutes ces avenues sont explorées, quand tous les doutes sont écartés, que l'article peut être rédigé et publié. Et dans sa rédaction, on retrouve l'un des critères les plus importants pour un fact-checker. Tout ce processus de fact-checking doit absolument être décrits dans ses moindres détails, et chaque étape doit pouvoir être reproduite par le lecteur.

Quand on considère la complexité de ce processus, ainsi que l'importance que les journalistes portent sur sa reproductibilité, les méthodes actuelles utilisées par les systèmes d'AFC semblent presque primitives. Presqu'aucune explicabilité, aucune reproductibilité et une rigueur bien moindre que celle possédée par les journalistes.

Pendant les Assises du Journalisme, une personne a mentionné *AskVera*, le système d'AFC accessible à partir de WhatsApp et que des informaticiens dans le domaine des AFC avait prôné comme étant une sorte d'idéal à améliorer. Les journalistes dans la salle ont ri.

2.3 Un objectif qui semble impossible

Si ce rire peut paraître plus que surprenant au premier abord, quand on prend du recul sur les systèmes d'AFC actuellement développés, ce rejet peut devenir presque compréhensible.

Nous pensons que cela est lié à plusieurs raisons. La première est que les systèmes d'AFC sont entraînés, ou utilisent pour sources, les articles écrits par des organismes de fact-checking. Les mêmes articles qui sont utilisés, par ailleurs, dans les benchmarks de ces systèmes. Cela implique que les systèmes d'AFC perdent énormément en efficacité lorsque que des fake news nouvelles, qui n'ont donc jamais été traitées par des journalistes, sont données au système. De même, VERITAS a montré que tous les systèmes basés sur des LLM perdaient énormément en précision lorsque des fake news publiées après la date de fin d'entraînement du modèle utilisé sont fournies à ces systèmes.

Quand on ajoute à ces problèmes le manque d'explicabilité, l'absence de vérification du contexte, et l'impossibilité pour un humain de reproduire ce que le système a fait, les AFC actuels semblent alors très vite inadéquats. D'un point de vue cynique, les systèmes d'AFC servent de moteurs de recherches spécialisés dans les articles de fact-checkers. Des moteurs de recherches qui ne sont même pas si efficaces, et cela même quand les articles contenus dans les benchmarks sont utilisables par les systèmes d'AFC en tant que source.




Figure 4: Graphique montrant la perte d'efficacité des LLM après la fin de leur entraînement.

Cette observation n'est pas nouvelle. Pendant mes recherches, j'ai lu trois articles qui allaient dans ce sens, et qui m'ont permis d'arriver à cette conclusion.

Le premier article que j'aimerais mettre en avant est VERITAS. Comme mentionné précédemment, c'est une base de données qui a pour vocation d'être utilisée par les AFC afin de tester leur efficacité. Mais VERITAS ne s'arrête pas là. La majorité de l'article critique en effet les pratiques majoritairement utilisées dans le monde de l'AFC ; la dépendance sur les LLM, le manque de qualité présent dans la plupart des datasets, et le manque critique d'efficacité et d'explicabilité des systèmes d'AFC.

Le second article est *Show me the Work* [2]. Cet article ne présente pas de nouvelles solutions, mais résume plutôt des interviews que les autrices ont réalisés avec des journalistes sur leur métier et sur les attentes qu'ils avaient pour un système d'AFC. Cet article remet entièrement en question tous les systèmes d'AFC. Leur manque d'explicabilité et leur méthodologie sont plus que critiqués. S'il ne propose pas de réelle solution, il nous a permis de définitivement sortir du "sens commun" qui semble être présent dans la majorité des systèmes d'AFC. Il inclut néanmoins certaines attentes présentées par les journalistes, et celles-ci devraient guider n'importe quel AFC.

Le dernier article est "Image, Tell me your story!" [3]. Celui-ci présente un système d'AFC avec des résultats qui sont bien inférieurs à ceux que nous pouvons constater dans le reste du monde scientifique. Cependant, la méthodologie pour arriver à ces résultats est très intéressante. Plutôt que de questionner la factualité du claim donné, l'AFC proposé (qui ne traite que des images), effectue une analyse presque sémiotique de chaque image. Lors de son processus, l'AFC répond à 5 questions : est-ce que l'image a déjà été utilisé auparavant, quelle est sa source, quelle est sa date, où a-t-elle été prise, et pourquoi a-t-elle été prise. Ces questions, qui se rapprochent très fortement de celles qu'un journaliste peut se poser, permettent ensuite au système d'aider le fact-checker dans son raisonnement. Ce processus, qui allait tellement à l'encontre du reste du monde scientifique, nous a particulièrement marqué.

Après avoir obtenu toutes ces informations, après avoir assisté aux Assises du Journalismes, et après avoir lu

ces articles, il est devenu impossible pour nous de simplement essayer de créer un nouveau système d’AFC. Les résultats seraient tout aussi décevants, et nous n’apporterions rien de réellement nouveau à ce domaine qui est pourtant si important. Nous nous sommes donc efforcés d’identifier une autre approche.

3 Une autre approche

Une fois que nous avons observé la réalité décevante des systèmes d’AFC actuels, nous nous devions d’essayer de trouver une alternative plus prometteuse. Ceci est alors devenu le nouvel objectif de ce stage. Plutôt que de créer un énième système qui ne sera probablement jamais adopté, nous allions essayer de réaliser un Proof of Concept d’un AFC qui correspondrait plus aux critères des journalistes.

3.1 L’AFC au service du journalisme

Quand on lit les articles scientifiques à la base des systèmes d’AFC, on remarque que les chercheurs parlent de remplacer les journalistes fact-checkers. C’est l’objectif final ; que chaque information puisse être vérifiée par un citoyen avec la justesse d’un fact-checker humain, afin que la factualité triomphe définitivement. Les systèmes d’AFC sont donc, traditionnellement, destinés à être utilisés par le citoyen lambda.

Cependant, ce rôle demande aux AFC une rigueur qui n’est pas vraiment atteignable, en tout cas avec les technologies actuelles. La factualité est un domaine qui ne peut pas se satisfaire d’un “simple” 0.95 de score F1, ce qui serait excellent dans la quasi-totalité des autres situations. Quand on parle de factualité, il est nécessaire que toutes les réponses soient correctes, car une seule erreur peut avoir des conséquences très graves. De plus, un système d’AFC qui n’a pas tout le temps raison, qui peut changer sa réponse d’un prompt à l’autre, ou qui peut être jailbreak, représente un risque réel pour notre démocratie. Un risque qui est par exemple reconnu par les auteurs de VERITAS, qui n’est pas accessible sans l’accord des créateurs, car un tel dataset pourrait servir pour générer plus facilement des fake news.

Nous proposons alors de recentrer la conversation sur les journalistes eux-mêmes. Plutôt que d’essayer de les remplacer, les systèmes d’AFC pourraient être développés afin de les aider dans leur travail. Ce n’est pas une idée qui vient de nulle part, car les journalistes présents aux Assises ont mentionné qu’ils seraient ravis de pouvoir utiliser un système qui ferait toutes les tâches informatiques à leur place. Ces tâches, parmi lesquelles on trouve la RIS, la reconnaissance faciale, ou encore l’extraction et l’analyse des métadonnées, peuvent prendre beaucoup de temps. Elles demandent aussi une maîtrise et une compréhension de ces technologies qui n’est pas universelle.

De même, les journalistes interrogés dans Show me the Work mentionnent qu’ils sont intéressés par les AFC, mais que ceux qui sont développés actuellement ne sont pas assez fiables ou explicables.

Pour toutes ces raisons, nous pensons qu’il y a un réel intérêt inexploré dans la création d’un AFC qui serait destiné à l’utilisation des journalistes. En plus de répondre à un réel besoin, un tel système ne demanderait pas la même rigueur en termes de résultat qu’un AFC destiné à des citoyens. Si l’AFC est utilisé par des journalistes afin de les aider à la rédaction d’un article de fact-checking, alors il n’est pas nécessaire qu’il soit toujours correct. Etant donné qu’un humain informé sera présent pour vérifier toutes les assertions émises par ce système, si une d’entre elle est fausse ou peu pertinente, elle peut être ignorée sans causer de problème. De même, en utilisant directement des outils qui se rapprochent de ceux utilisés par les fact-checkers, il est par nature plus simple pour eux de reproduire leur fonctionnement. Cela remplit donc le critère de reproductibilité demandé par les articles de fact-checking, tout en permettant aux journalistes d’utiliser ce système même s’ils ne lui font pas nécessairement confiance. En utilisant un ensemble d’outils de fact-checkers et un raisonnement qui se rapproche de celui d’un humain, le système d’AFC devient explicable par nature et recentre l’AFC sur le processus, et non sur le résultat final.

3.2 Système proposé

Dans cette section, nous allons analyser le système d’AFC que nous proposons. Celui-ci n’a pas été entièrement réalisé dans le cadre de ce stage, étant donné la courte durée de celui-ci. Il a cependant été testé avec des outils qui ne demandaient pas d’être codés, et le résultat de ce test sera présenté à la fin de cette section.




Figure 5: Workflow du système d'AFC proposé.

3.2.1 Explications

Le système commence avec une source initiale. Celle-ci peut prendre la forme d'une image, d'une vidéo, ou, encore plus simplement, d'un lien vers un post sur un réseau social. En effet, avec la librairie yt-dlp (<https://github.com/yt-dlp/yt-dlp>), il est possible de télécharger une vidéo d'un réseau social (comme Youtube, Instagram, X, ou Tiktok). Cela permet une utilisation plus simple pour les journalistes, ainsi qu'une inclusion plus complète du contexte du claim. Une fake news n'est en effet pas anonyme, et pouvoir connaître la personne qui l'a postée peut être essentiel dans l'identification de sa nature.

Si le post contient une image, une vidéo ou de l'audio, alors ces données sont envoyées au module de vision. Celui-ci permet d'effectuer une analyse de ce média grâce à différents outils (transcription, description, sélection de keyframes, etc). Celui-ci a été réalisé dans le cadre de ce stage, et il sera décrit plus en détails dans la section suivante.

Certaines de ces informations sont ensuite envoyées aux modules de contexte. Ceux-ci permettent d'aller chercher du contexte sur Internet, de le synthétiser, et de détecter si davantage de contexte est nécessaire. On peut alors penser à faire une analyse simple des comptes que la source suit, de regarder la description de son profil, son nombre de followers, ou encore un simple historique de ses posts. On pourrait aussi utiliser des outils simples de OSINT afin de regarder si le pseudo de celui qui a posté le claim est utilisé sur d'autres sites ou s'il est associé à une certaine nationalité. Enfin, c'est ici et en coopération avec le module de vision qu'une RIS peut être effectuée.

L'importance du contexte d'une fake news n'est pas à sous-estimer. Les journalistes l'utilisent souvent, et certains parlent même de faire une analyse sémiotique afin de déterminer la factualité du contenu. Dans le domaine des AFC, on retrouve l'article *Fake News Detection on Social Media using Geometric Deep Learning* [1] qui permettait de prédire la factualité d'un post en fonction des interactions de l'utilisateur. Un raisonnement qui marchait étonnamment bien, et qui a en partie inspiré ces modules.

Toutes ces informations (celles du module de vision et des modules de contexte) sont ensuite fournies à un LLM afin qu'elles soient résumées. Si les LLM sont des boîtes noires et donc pas forcément les meilleurs outils d'un point de vue explicabilité, ils restent des outils essentiels pour le traitement du langage naturel. L'information brute des modules n'est aussi pas supprimée, et l'utilisateur peut la consulter facilement. Cependant, avoir un résumé court de ce qui est important permet à de futurs modules de mieux traiter l'information.

Avec ce résumé, ainsi que le contenu du post original, un LLM identifie ensuite le ou les claim(s) réalisé(s) par le post. On entre alors dans la prédiction de la véracité de ces claims, une fonctionnalité qui n'est, en réalité, que secondaire par rapport au reste du processus. Le plus important, selon nous, et la collecte d'information qui se déroule au préalable. Cependant, il est important de ne pas complètement abandonner

ce qui a été fait par la communauté scientifique. Un processus d'identification de claims et d'estimation de leur véracité permet de s'aligner sur des datasets existants.

Une fois le(s) claim(s) identifié(s), des recherches internet sont effectuées. Ceci est assez similaire à ce que 3M-Fact fait : un LLM génère des questions, une recherche est effectuée, et si un manque d'information est détecté, alors une autre recherche est lancée. Le processus se répète jusqu'à ce qu'il y ait suffisamment d'information, ou si une limite arbitraire est atteinte.

Une fois ces recherches effectuées, toutes les données sont fournies à un LLM qui effectue une décision finale sur le statut de véracité de chaque claim détecté. La décision est expliquée en se basant sur les preuves trouvées, et donc non seulement sur l'entraînement du LLM ou sur des sources fournies au préalable.

Cette décision est ensuite jugée par un autre module dirigé par un autre LLM. Celui-ci reprend le post fourni initialement et détermine si les claims identifiés et les conclusions trouvés sont cohérents avec cet input. Si ce n'est pas le cas, alors il peut faire appel à certains modules intermédiaires afin de demander des analyses supplémentaires.

Enfin, une explication est générée. Ici, le format est libre, mais nous sommes intéressés par la création d'un graphe. Chaque module serait représenté par une node, qui pourrait être sélectionné afin de voir plus de détails. Les outputs purs des outils utilisés par le module de vision, de contexte, ou de sources pourraient être inspectés. On pourrait aussi penser à faire une estimation de l'importance de chaque donnée sur la décision finale, et de changer la taille des nodes en fonction. Nous pensons qu'il est intéressant d'explorer d'autres avenues d'explicabilité dans le domaine des AFC que du simple texte, ou une citation des sources utilisées.

3.2.2 Exemple

Afin de vérifier le potentiel de cette idée, nous avons effectué un test de ce workflow sur une fake news. Ce test a été réalisé avec des outils utilisables en python, afin qu'ils puissent être potentiellement implémentés dans une version future de l'algorithme. Le LLM qui a été utilisé est la version disponible en ligne de Claude Sonnet 4.6.

Le post que nous avons choisi se trouve dans cet article :

<https://factoscope.fr/factoscope/non-cette-image-ne-montre-pas-un-bombardement-iranien-en-cote-divoire/>

Il provient de Factoscope, un site français de fact-checking.

Nous avons trouvé les résultats de ce test très prometteurs. Sans trop rentrer dans les détails (qui sont disponibles en annexe), l'algorithme a suivi un raisonnement humain, journalistique. La RIS a permis d'identifier un contexte incohérent, l'analyse de la personne qui a posté l'information a indiqué un profil commun chez les désinformateurs, et des recherches sur internet ont vérifié que ce qui était dit était faux.

A un moment dans le processus, un article de l'AFP (Agence France Presse) a été trouvé et a directement indiqué que c'était une fake news. Si la plupart des systèmes d'AFC se seraient arrêtés là, le nôtre n'a utilisé celui-ci que comme quatrième preuve de son jugement. Le système a montré une redondance et une rigueur similaire à celle que l'on peut trouver dans les articles des journalistes. Et si toutes les informations n'étaient pas pertinentes, cela n'est, encore une fois, pas un si grand problème que ça. Ce système n'ayant pas pour vocation d'être utilisé par un citoyen, sa perfection n'est pas requise.

3.3 Module de vision réalisé

Devant un résultat aussi intéressant, nous avons décidé de réaliser un Proof of Concept du module de vision, ainsi qu'une simple représentation graphique qui permettrait de montrer le potentiel explicatif d'un graph.

Les outils utilisés sont décrits dans le tableau et l'image qui suivent.




Figure 6: Workflow du module de vision.

Une implémentation du module de vision a été réalisé et est disponible sur le git suivant : <https://github.com/Azulia888/stage-M1>

Une simple interface GUI permet d’interagir avec le programme et d’observer le comportement et les résultats de l’algorithme. Les résultats sont disponibles dans le dossier “results”, où les analyses de 10 vidéos provenant de VERITAS ont été enregistrées. Chaque dossier correspond à une vidéo, où on peut retrouver les logs de la console ainsi qu’un fichier pkl qui permet d’importer les résultats directement dans l’interface graphique.

Le code du projet est dans le dossier “projet” (le reste contient des annexes ou les restes d’anciens tests, conservés pour la postérité).

Il est important de noter que parmi les outils initialement proposés, la détection de génération par IA et la détection de DeepFake n’ont pas été programmés. Nous avons estimé que ces outils existaient déjà de façon suffisamment modulable, et que nous n’allions rien révolutionner en les rajoutant.

Les 10 vidéos sélectionnées essaient de montrer la diversité des fake news sur internet ; contexte incorrect, factualité fausse, génération par IA et montage de clips qui n’ont rien à voir. Pareillement, la durée varie fortement, allant d’une dizaine de secondes jusqu’à cinq minutes.

D’un point de vue du code, les outils de Description, d’OCR, de NER, d’analyse de la météo, de la géolocalisation, d’analyse des métadonnées et de reconnaissance faciale ont été implémentés en utilisant un LLM local. Le modèle utilisé dans le cadre de ce stage a été Qwen 3.5 (2b paramètres) avec Ollama. C’est un modèle qui peut voir les images qu’on lui fournit, une qualité essentielle dans notre contexte. Si nous voulions originellement utiliser des vLLM pour faire de l’analyse de vidéos, nous avons dû nous contenter d’utiliser un LLM avec de la vision pour faire de l’analyse fragmentée de keyframes et du transcript, car les vLLM demandaient trop de ressources.

Pour pallier à cette limitation, tous les outils qui utilisent la vision font d’abord une analyse sur chacune des keyframes extraites. Un dernier appel prend en entrée chacun de ces résultats et les résume en un seul texte qui s’approche donc d’une description complète.

En plus des outils du module de vision inclus dans le tableau et l’image, nous avons aussi implémenté un outil de RIS et un outil qui permet de connecter les résultats du NER à un Knowledge Graph (KG).

Le premier utilise SerpApi de Google pour faire des RIS. Ceci est possible en utilisant les 250 requêtes gratuites par mois que cette API fourni. Le second se connecte au KG de Wikidata afin de compléter les éléments identifiés par l’outil de NER avec des informations en lesquelles nous pouvons avoir confiance.

Tool	Data	Why?	How?	FC-task	Corroborating Tools	Required External Evidence	XAI Applications
Keyframe extraction	Video	Used in other image-only tools	Katna; Other techniques				Selected frames should be shown
Transcript	Video	Used in other text-only tools	STT technologies				
Description	Video	Used in other text-only tools	VLM				
Optical Character Recognition (OCR)	Image	Identifying dates, locations, people; detecting inconsistencies	OCR technologies	OOc detection	Title; Transcript	Information about the identified elements	Directly showing the inconsistencies
Deepfake Detection	Video	Detecting deepfake	Deepfake detection tools	Manipulation Classification			Results + Confidence
AI Detection	Video; Image	Detecting AI-generated media	AI-generated media detection tools	Manipulation Classification			Results + Confidence
Metadata Analysis	Metadata	Can help detect inconsistencies with information from other tools	yt-dlp retrieves metadata from SNS; EXIF	OOc detection	Title; Transcript; Description; OCR	Information about the poster	Inconsistencies detected
Lip-sync Detection	Video; Audio	Detecting out-of-context or manipulated audio	SyncNet; Wav2Lip	Manipulation Classification	Deepfake/AI Detection		Results + Confidence
Weather Detection	Video; Image	Detecting if the weather for the claimed date/location is coherent	VLM; Specialized CNNs	OOc detection	Metadata; Geolocation	Actual reports for the claimed date/location	Identified weather and (in)consistencies
Geolocation	Image	Detecting if the identified location is the same as the one claimed	Landmark recognition; GeoSpy	OOc detection	Metadata; Transcript		Identified location (in)consistencies
Facial Recognition	Video; Image	Detecting famous people allows us to detect potential inconsistencies in what is claimed	Specialized model with a famous people database	Manipulation Detection Veracity Classification	Deepfake/AI Detection; Transcript	Wikipedia pages of identified people	(In)consistencies between claimed discourse and actual opinions
Named Entity Recognition (NER)	Transcript OCR Description	Allows for further connections to KG	spaCy	Claim Identification	Transcript; Description	KG related to identified named entities	Found entities and why (+ connections to KG)

Pour cela, on utilise l’endpoint qui permet d’effectuer une recherche d’un élément à partir de son nom. Nous prenons alors le QID du premier résultat, et nous effectuons une recherche sur l’endpoint SPARQL afin d’obtenir les informations désirées. Cela n’est pas parfait, et le système de NER donne parfois des informations inutiles, mais nous pensons que cette version est suffisante pour notre Proof of Concept.

Ceci représente par ailleurs le mot d’ordre de cette implémentation. De nombreux problèmes existent, et les améliorations possibles sont infinies. Cependant, nous pensons qu’elle montre déjà le potentiel de cette façon de penser. Le raisonnement suivi est humain, explicable. Les résultats ne sont pas les meilleurs, mais un lecteur attentif pourrait déjà les utiliser afin de déterminer les claims du post donné, ainsi que leur factualité. Le manque de temps et de puissance de calcul ayant été des facteurs majeurs de ces limitations, nous restons donc convaincus de l’intérêt de cette position, et nous espérons que certains s’inspirent de nos travaux afin de réaliser un système plus complet.

4 Conclusion

Ce stage, qui avait pour objectif initial de construire un système d’AFC qui serait multimodal et explicable, ne s’est pas déroulé comme prévu. La possibilité d’assister aux Assises du Journalisme ainsi que la lecture de certains articles clés m’ont permis de prendre du recul sur le sujet. Nous avons pu identifier certaines incohérences et certains problèmes dans le raisonnement autour des AFC.

Nous avons donc proposé un autre système, une autre vision. Une perception de l’AFC qui ne serait pas destiné à l’utilisation par le citoyen lambda, et qui chercherait donc à remplacer les journalistes, mais de l’AFC pour soutenir ces journalistes dans leur travail. A travers la création d’un pipeline simple, de son test, et de l’implémentation de certains de ses modules les plus importants, nous pensons avoir démontré que la poursuite de cette vision représente un réel enjeu pour le futur des systèmes d’AFC. Notre Proof of Concept possède évidemment de nombreuses limitations, mais nous pensons qu’elles peuvent toutes être réglées avec suffisamment de temps et de puissance de calcul.

Plus que tout autre chose, nous espérons que ces travaux permettront d’élargir la réflexion autour du domaine de l’AFC. Nous pensons en effet qu’une sorte de “sens commun” limitant a été établi au cours du temps, et qu’il est nécessaire de s’en affranchir si nous voulons obtenir des résultats réellement intéressants.

References

- [1] Monti Federico et al. “Fake News Detection on Social Media using Geometric Deep Learning”. In: (2019). DOI: <https://doi.org/10.48550/arXiv.1902.06673>.
- [2] Warren Greta, Shklovski Irina, and Augenstein Isabelle. “Show Me the Work: Fact-Checkers’ Requirements for Explainable Automated Fact-Checking”. In: *CHI ’25: Proceedings of the 2025 CHI Conference on Human Factors in Computing Systems* (2025). DOI: <https://doi.org/10.1145/3706598.3713277>.
- [3] Tonglet Jonathan, Moens Marie-Francine, and Gurevych Iryna. “”Image, Tell me your story!” Predicting the original meta-context of visual misinformation”. In: *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing* (2024). DOI: <https://doi.org/10.48550/arXiv.2408.09939>.
- [4] Niu Kaipeng et al. “Pioneering Explainable Video Fact-Checking with a New Dataset and Multi-role Multimodal Model Approach”. In: *Proceedings of the AAAI Conference on Artificial Intelligence* (2025). DOI: <https://doi.org/10.1609/aaai.v39i27.35048>.
- [5] Mark Rothermel et al. “VeriTAS: The First Dynamic Benchmark for Multimodal Automated Fact-Checking”. In: (2026). DOI: [arXiv:2601.08611](https://arxiv.org/abs/2601.08611). URL: <https://doi.org/10.48550/arXiv.2601.08611>.